

# Método de la Potencia y PCA

Métodos Numéricos

29 de mayo de 2020

# Autovalores y Autovectores

## Definición

Sea  $A \in \mathbb{R}^{n \times n}$ . Un *autovector* de  $A$  es un vector no nulo tal que  $Ax = \lambda x$ , para algún escalar  $\lambda$ . Un escalar  $\lambda$  es denominado *autovalor* de  $A$  si existe una solución no trivial  $x$  del sistema  $Ax = \lambda x$ . En este caso,  $x$  es llamado *autovector asociado a  $\lambda$* .

Consideramos:

$$A = \begin{bmatrix} 3 & -2 \\ 1 & 0 \end{bmatrix}, u = \begin{bmatrix} -1 \\ 1 \end{bmatrix}, v = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

$$Au = \begin{bmatrix} -5 \\ -1 \end{bmatrix}, Av = \begin{bmatrix} 4 \\ 2 \end{bmatrix} = 2 \begin{bmatrix} 2 \\ 1 \end{bmatrix} = 2v$$

Gráficamente.... $A$  sólo estira (o encoge) el vector  $v$ .

# Autovalores y autovectores

Dada una matriz  $A \in \mathbb{R}^{n \times m}$ , un vector  $\mathbf{x} \in \mathbb{R}^m$  no nulo puede ser paralelo a  $A\mathbf{x}$ , lo que significa que existe una constante  $\lambda$  tal que  $A\mathbf{x} = \lambda\mathbf{x}$ .


A todos los  $\mathbf{x}$  que cumplen esta propiedad se los denomina autovectores de  $A$  y  $\lambda$  su autovalor asociado.

# Autovalores y autovectores

Dada una matriz  $A \in \mathbb{R}^{n \times m}$ , un vector  $\mathbf{x} \in \mathbb{R}^m$  no nulo puede ser paralelo a  $A\mathbf{x}$ , lo que significa que existe una constante  $\lambda$  tal que  $A\mathbf{x} = \lambda\mathbf{x}$ .

A todos los  $\mathbf{x}$  que cumplen esta propiedad se los denomina autovectores de  $A$  y  $\lambda$  su autovalor asociado.

Representación gráfica:



En muchos casos, la presencia de autovectores-autovalores puede ser utilizada para encontrar una factorización  $A = PDP^{-1}$ , donde  $D$  es una matriz diagonal.

### Intuición

Podemos encontrar una base donde la transformación lineal  $A$  se comporta como si fuese diagonal.

### Observación

No toda matriz  $A \in \mathbb{R}^{n \times n}$  es diagonalizable.

### Teorema

Una matriz  $A \in \mathbb{R}^{n \times n}$  es diagonalizable sí y solo sí  $A$  tiene  $n$  autovectores linealmente independientes (las columnas de  $P$ ).

# Más teoremas

## Teorema Espectral

Si  $A \in \mathbb{R}^{n \times n}$  es simétrica, entonces existe una base ortonormal de autovectores  $\{v_1, \dots, v_n\}$  asociados a  $\lambda_1, \dots, \lambda_n$ .

Consecuencia: Existe  $P$ , y  $P^{-1} = P^t$ . Luego,  $A = PDP^t$ .

## Teorema

Sea  $A \in \mathbb{R}^{m \times n}$ . Luego, si  $\lambda$  es autovalor de  $A^T A$ , con autovector  $v$  entonces  $\lambda$  es también autovalor de  $AA^T$  con autovector  $Av$ .

# Diagonalización

En muchos casos, la presencia de autovectores-autovalores puede ser utilizada para encontrar una factorización  $A = PDP^{-1}$ , donde  $D$  es una matriz diagonal.

## Intuición

Podemos encontrar una base donde la transformación lineal  $A$  se comporta como si fuese diagonal.

## Observación

No toda matriz  $A \in \mathbb{R}^{n \times n}$  es diagonalizable.

## Teorema

Una matriz  $A \in \mathbb{R}^{n \times n}$  es diagonalizable sí y solo sí  $A$  tiene  $n$  autovectores linealmente independientes (las columnas de  $P$ ).

# Teorema Espectral

## Teorema

Si  $A \in \mathbb{R}^{n \times n}$  es simétrica, entonces existe una base ortonormal de autovectores  $\{v_1, \dots, v_n\}$  asociados a  $\lambda_1, \dots, \lambda_n$ .

Consecuencia: Existe  $P$ , y  $P^{-1} = P^t$ . Luego,  $A = PDP^t$ .



# Cálculo de autovalores/autovectores

- ▶ La matriz de covarianza  $M_X = \frac{1}{n-1}X^tX$  es simétrica y semidefinida positiva.
- ▶ Vamos a querer diagonalizar  $M_X$  para obtener la transformación que queremos. Para eso vamos a calcular sus autovectores.
- ▶ Podemos considerar el Método de la Potencia para calcular  $\lambda_1$  y  $v_1$ .

1. MetodoPotencia( $B, x_0, niter$ )
2.  $v \leftarrow x_0$ .
3. Para  $i = 1, \dots, niter$
4.  $v \leftarrow \frac{Bv}{||Bv||}$
5. Fin Para
6.  $\lambda \leftarrow \frac{v^t Bv}{v^t v}$
7. Devolver  $\lambda, v$ .

# Cálculo de autovalores/autovectores

Una vez que tenemos  $\lambda_1$  y  $v_1$ , como seguimos?

## Deflación

Sea  $B \in \mathbb{R}^{n \times n}$  una matriz con autovalores distintos

$|\lambda_1| > |\lambda_2| > \dots > |\lambda_n|$  y una base ortonormal de autovectores.

Entonces, la matriz  $B - \lambda_1 v_1 v_1^t$  tiene autovalores  $0, \lambda_2, \dots, \lambda_n$  con autovectores asociados  $v_1, \dots, v_n$ .

- ▶  $(B - \lambda_1 v_1 v_1^t)v_1 = Bv_1 - \lambda_1 v_1(v_1^t v_1) = \lambda_1 v_1 - \lambda_1 v_1 = 0v_1$ .
- ▶  $(B - \lambda_1 v_1 v_1^t)v_i = Bv_i - \lambda_1 v_1(v_1^t v_i) = \lambda_i v_i$ .

## Observación


En nuestro caso, no hace falta que todos los autovalores tengan magnitudes distintas.

# Análisis de Componentes Principales

Ejemplo datos en  $\mathbb{R}^2$

Sean  $x^{(1)}, x^{(2)}, \dots, x^{(n)}$  una secuencia de  $n$  datos, con  $x^{(i)} \in \mathbb{R}^2$ .


$$X = \begin{bmatrix} x^{(1)t} \\ x^{(2)t} \\ x^{(3)t} \\ x^{(4)t} \\ x^{(5)t} \\ x^{(6)t} \\ \vdots \\ x^{(n)t} \end{bmatrix} = \begin{bmatrix} 26,4320 & 27,7740 \\ 26,8846 & 26,5631 \\ 23,3309 & 26,6983 \\ 30,6387 & 31,5619 \\ 30,5171 & 30,8993 \\ 45,6364 & 36,6035 \\ \vdots & \vdots \\ 16,0650 & 24,0210 \end{bmatrix}$$



# Análisis de Componentes Principales

Ejemplo datos en  $\mathbb{R}^2$

$$X = \begin{bmatrix} 26,4320 & 27,7740 \\ 26,8846 & 26,5631 \\ 23,3309 & 26,6983 \\ 30,6387 & 31,5619 \\ 30,5171 & 30,8993 \\ 45,6364 & 36,6035 \\ \vdots & \vdots \\ 16,0650 & 24,0210 \end{bmatrix}$$



Media:

$$\mu = \frac{1}{n}(x^{(1)} + \dots + x^{(n)})$$

$$\mu = (29,3623, 29,7148)$$

Varianza de una variable  $x_k$ : Medida para la dispersión de los datos.

$$\sigma^2 = \frac{1}{n-1} \sum_{i=1}^n (x_k^{(i)} - \mu_k)^2$$

$$\sigma_{x_1}^2 = 66,2134, \sigma_{x_2}^2 = 12,5491$$

# Análisis de Componentes Principales

Ejemplo datos en  $\mathbb{R}^2$  - Covarianza

Covarianza: Medida de cuánto dos variables varían de forma similar. Variables con mayor covarianza inducen la presencia de cierta dependencia o relación.

$$\sigma_{x_j x_k} = \frac{1}{n-1} \sum_{i=1}^n (x_j^{(i)} - \mu_j)(x_k^{(i)} - \mu_k)$$

# Análisis de Componentes Principales

## Ejemplo datos en $\mathbb{R}^2$ - Covarianza

Dadas  $n$  observaciones de dos variables  $x_1$ ,  $x_2$ , y  $v = (1, \dots, 1)^t$ :

$$\sigma_{x_1 x_2} = \frac{1}{n-1} \sum_{i=1}^n (x_1^{(i)} - \mu_1)(x_2^{(i)} - \mu_2) = \frac{1}{n-1} (x_2 - \mu_2 v)^t (x_1 - \mu_1 v)$$

Matriz de Covarianza:

$$X = \begin{bmatrix} 26,4320 - \mu_1 & 27,7740 - \mu_2 \\ 26,8846 - \mu_1 & 26,5631 - \mu_2 \\ 23,3309 - \mu_1 & 26,6983 - \mu_2 \\ 30,6387 - \mu_1 & 31,5619 - \mu_2 \\ 30,5171 - \mu_1 & 30,8993 - \mu_2 \\ 45,6364 - \mu_1 & 36,6035 - \mu_2 \\ \vdots & \vdots \\ 16,0650 - \mu_1 & 24,0210 - \mu_2 \end{bmatrix}$$
$$M_X = \frac{1}{n-1} X^t X = \begin{bmatrix} \sigma_{x_1 x_1} & \sigma_{x_1 x_2} \\ \sigma_{x_1 x_2} & \sigma_{x_2 x_2} \end{bmatrix}$$
$$= \begin{bmatrix} \sigma_{x_1}^2 & \sigma_{x_1 x_2} \\ \sigma_{x_1 x_2} & \sigma_{x_2}^2 \end{bmatrix}$$
$$M_X = \begin{bmatrix} 66,2134 & 27,1263 \\ 27,1263 & 12,5491 \end{bmatrix}$$

# ¿Cómo expresar mejor nuestros datos?

## Objetivo


Buscamos una transformación de los datos que disminuya la redundancia (es decir, disminuir la covarianza).

- ▶ Cambio de base:  $\hat{X}^t = PX^t$ .
- ▶ Cómo podemos hacerlo? Diagonalizar la matriz de covarianza. Esta matriz tiene la varianza de cada variable en la diagonal, y la covarianza en las restantes posiciones. Luego, al diagonalizar buscamos variables que tengan covarianza cero entre sí y la mayor varianza posible.

# ¿Cómo expresar mejor nuestros datos?

Volvemos al ejemplo

$$\begin{aligned} M_X &= \begin{bmatrix} 66,2134 & 27,1263 \\ 27,1263 & 12,5491 \end{bmatrix} \\ &= \underbrace{\begin{bmatrix} 0,9228 & -0,3852 \\ 0,3852 & 0,9228 \end{bmatrix}}_V \underbrace{\begin{bmatrix} 77,5362 & 0 \\ 0 & 1,2263 \end{bmatrix}}_{D=M_{\hat{X}}} \underbrace{\begin{bmatrix} 0,9228 & 0,3852 \\ -0,3852 & 0,9228 \end{bmatrix}}_{V^t} \end{aligned}$$





# Análisis de Componentes Principales

## Resumen hasta acá

- ▶ Tenemos  $n$  muestras de  $m$  variables.
- ▶ Calculamos el vector  $\mu$  que contiene la media de cada una de las variables.
- ▶ Construimos la matriz  $X \in \mathbb{R}^{n \times m}$  donde cada muestra corresponde a una fila de  $X$  y tienen media cero (i.e.,  $X_i := (x^{(i)} - \mu)$ ).
- ▶ Diagonalizamos la matriz de covarianzas  $M_X = \frac{X^t X}{n-1}$ . La matriz  $V$  (ortogonal) contiene los autovectores de  $M_X$ .

## Propiedades del cambio de base

- ▶ Disminuye redundancias.
- ▶ El cambio de base  $\hat{X}^t = P X^t = V^t X^t$  asigna a cada muestra un nuevo *nombre* mediante un cambio de coordenadas.
- ▶ Las columnas de  $V$  (autovectores de  $M_X$ ) son las componentes principales de los datos.
- ▶ En caso de  $m$  grande, es posible tomar sólo un subconjunto de las componentes principales para estudiar (i.e., aquellas que capturen mayor proporción de la varianza de los datos).